

RESEARCH ARTICLE

基于多层感知机的多层介质薄膜光谱预测与辅助设计

MLP-Based Spectral Prediction and Data-Driven Design of Multilayer Dielectric Thin Films

姓名：潘欣宁 学号：2023270026

 λ_{target} : 710 nm seed: 270026 design_seed: 270027

Abstract

多层介质膜的光谱响应由各层厚度决定，传输矩阵法虽能精确计算，但在大规模参数筛选中逐点计算开销较大。本文以 Air/H/L/H/L/Glass 四层膜系为对象，用传输矩阵法生成 5000 组膜厚—反射光谱样本，训练结构为 4-128-128-64-41 的多层感知机（MLP）代理模型，在固定 500 组测试集上的预测均方根误差为 0.0107。训练样本由 500 增至 4000 时，测试 RMSE 从 0.0309 单调降至 0.0107，收益边际递减。进一步用 MLP 对 10000 组新候选膜系按 710 nm 目标波长处的反射率排序，Top-10 经传输矩阵法复核后确定 Top-5 设计，最优结构反射率为 0.6578。结果表明 MLP 能够快速近似膜厚—光谱映射并有效缩小候选范围，但排序与最终性能评估仍需以 TMM 计算为准。

Keywords: optical thin films; transfer matrix method; multilayer perceptron; surrogate model; AI for Science

1. Introduction

多层介质薄膜由折射率高低交替的介质层堆叠而成，是增透膜、高反射膜、滤光片和结构色等光学器件的核心结构^[1]。入射光在各层界面处发生多光束干涉，反射光谱的峰谷位置和包络形状由各层折射率与厚度共同决定，其中膜厚是设计中最直接的可调自由度。如何在给定层数和材料组合下选择各层厚度，使光谱在目标波长处满足设计要求，是多层膜设计的基本问题。

传输矩阵法（TMM）是计算多层膜反射光谱的经典方法。它把每一层膜写成 2×2 特征矩阵，将各层矩阵连乘后即可解析地得到任意波长下的振幅反射系数与反射率，计算量小且结果精确^[1,2]。在膜系优化中，TMM 常与 needle optimization 等搜索方法配合使用^[3]。然而，当设计需要在高维参数空间中评估大量候选结构时，TMM 逐点计算的开销随候选数量线性增长，成为批量筛选的瓶颈^[4]。

机器学习代理模型为这一问题提供了另一条路径。先用物理模型生成一批（结构参数，光谱）样本，再训练神经网络学习从参数到光谱的非线性映射；训练完成后，网络的单次前向推理远快于数值仿真，可用于大规模候选的快速评估。这一思路已在纳米光子结构的逆向设计中得到验证：Peurifoy 等用深度神经网络逼近纳米颗粒的光散射谱^[5]，Liu 等将网络用于纳米光子结构的逆向设计^[6]，Jiang 与 Fan 对神经网络在光子器件评估与设计中的应用做了系统综述^[7]。对多层膜这类一维层状结构，Ma 等对从传统优化到深度学习的逆向设计研究进行了梳理^[4]。

本文以固定的 Air/H/L/H/L/Glass 四层膜系为对象，围绕三个问题展开：MLP 能否准确预测四层介质膜的 41 点反射光谱；训练数据量如何影响预测误差；训练好的 MLP 能否用于大规模候选筛选并辅助目标波长下的膜系设计。整体工作流程如图 1 所示：先用 TMM 生成数据集并训练 MLP 代理模型，再通过训练数据量对照实验考察数据规模的影响，最后用 MLP 快速筛选候选膜系并以 TMM 复核结果。




Figure 1. Overall workflow of the AI4S thin-film study.

2. Materials and Methods

2.1 Optical model and transfer matrix method

研究对象统一为 Air/H/L/H/L/Glass 四层介质膜，正入射、无吸收并忽略色散。高、低折射率材料分别取 $n_H = 2.30$ 和 $n_L = 1.45$ ，玻璃基底 $n_s = 1.52$ ，每层膜厚在 40–180 nm 内变化。

$$\delta_i = 2\pi n_i d_i / \lambda$$

对每一层膜，特征矩阵为 $M_i = \begin{bmatrix} \cos \delta_i & (i/n_i) \sin \delta_i \\ i n_i \sin \delta_i & \cos \delta_i \end{bmatrix}$ ，其中 $\delta_i = 2\pi n_i d_i / \lambda$ 为该层的相位厚度。四层膜的总特征矩阵按空气侧到基底侧的顺序连乘，即 $M = M_1 M_2 M_3 M_4$ 。设入射介质折射率 $n_0 = 1$ （空气），基底折射率 $n_s = 1.52$ （玻璃），振幅反射系数为 $r = [(m_{11} + m_{12} n_s) \cdot n_0 - (m_{21} + m_{22} n_s)] / [(m_{11} + m_{12} n_s) \cdot n_0 + (m_{21} + m_{22} n_s)]$ ，反射率 $R(\lambda) = |r|^2$ 。代码按上式逐一计算 400–800 nm 内 41 个波长点的反射率，并用单层四分之一波长高折射率膜对实现做了校验：当 $d = \lambda_0 / (4n_H)$ 时， $R(\lambda_0) = 0.3065$ ，与解析值一致。




Figure 2. Physical model and TMM-based generation of thickness–spectrum data.

2.2 Student-specific target wavelength and random seed

目标波长与随机种子均由学号确定。设学号后两位为 N ，则 $\lambda_{\text{target}} = 450 + 10 \times (N \bmod 31)$ nm。基准随机种子 seed 取学号后 6 位整数；数据集生成、数据划分和 MLP 初始化均由该 seed 控制。为避免设计候选与训练数据重复，设计阶段采用 $\text{design_seed} = \text{seed} + 1$ 。

本文学号为 2023270026，后两位 $N = 26$ ，因此 $\lambda_{\text{target}} = 450 + 10 \times (26 \bmod 31) = 710$ nm。随机种子取学号后 6 位，即 $\text{seed} = 270026$ ，控制数据集采样、数据划分与网络权重初始化；设计阶段使用 $\text{design_seed} = 270027$ 生成候选，避免候选样本与训练数据重复。代码中通过 `random.seed`、`np.random.seed` 与 `torch.manual_seed` 显式设置上述种子，并固定 PyTorch 为单线程运算，以保证全部图表和数值可以复现。

2.3 Dataset generation

使用个人 seed 随机生成 5000 组膜厚组合，在 400–800 nm 范围内以 10 nm 步长计算反射率。一次固定随机排列后，将前 4000 组作为训练集、接下来 500 组作为验证集、最后 500 组作为测试集。此划分在后续所有实验中保持不变。

2.4 MLP surrogate model

MLP 输入为四层膜厚 $[d1, d2, d3, d4]$ ，输出为 41 个波长采样点的反射率。网络采用 4–128–128–64–41 结构：三个隐藏层分别含 128、128、64 个神经元，激活函数为 ReLU，输出层为线性。MLP 作为通用函数逼近器，足以拟合本问题中膜厚到光谱的光滑映射^[8]。

实际训练使用 Adam 优化器^[9]，学习率为 1×10^{-3} ，batch size 为 128，最大 epoch 为 1000，并采用以验证集损失为监控量、patience 为 100 的早停策略，保留验证误差最低的一组权重。输入膜厚按 $[40, 180]$ nm 区间做 Min-Max

归一化到[0, 1]；输出反射率本身位于[0, 1]，故输出层保持线性，不加 sigmoid。网络权重初始化由 $\text{seed} = 270026$ 控制，使各实验从同一组初始权重出发。




Figure 3. Architecture of the MLP surrogate model.

2.5 Training-size experiment

从固定 4000 组训练池中依次取前 500、1000、2000 和 4000 组训练模型；验证集和测试集始终使用固定的 500 组样本。除训练样本数外，其余训练设置保持一致。

2.6 MLP-assisted thin-film screening

使用 $\text{design_seed} = \text{seed} + 1$ 随机生成 10000 组新的候选膜厚，用训练完成的 MLP 预测其反射光谱，并按个人 λ_{target} 处的反射率排序。选择 Top 10 候选后，用 TMM 重新计算真实光谱，并确定最终 Top 5 设计。

3. Results

3.1 MLP training and spectral prediction

图 4 给出主模型（4000 个训练样本）的训练与验证损失曲线。两条曲线均在约 200 个 epoch 内降至 10^{-4} 量级，此后缓慢下降，训练与验证损失之间没有明显分离，未观察到过拟合。在固定的 500 组测试集上，模型最终 MSE 为 1.15×10^{-4} ，RMSE 为 0.0107，即反射率的平均预测误差约为 1%。图 5 给出三个测试样本上 TMM 真值与 MLP 预测光谱的对比：两者在 400–800 nm 范围内基本重合，干涉峰谷的位置和包络形状均得到较好还原。




Figure 4. Training and validation losses of the MLP surrogate model.




Figure 5. Comparison of TMM-calculated and MLP-predicted spectra on representative test samples.

3.2 Effect of training-set size

图 6 给出训练样本数与测试误差的关系。训练样本为 500、1000、2000、4000 时，测试集 RMSE 分别为 0.0309、0.0199、0.0136 和 0.0107，对应的 MSE 分别为 9.53×10^{-4} 、 3.95×10^{-4} 、 1.84×10^{-4} 和 1.15×10^{-4} 。误差随训练样本数增加单调下降，但下降速度逐渐放缓：样本数从 500 增至 1000 时 RMSE 下降约 0.011，而从 2000 增至 4000 时仅下降约 0.003，呈现边际收益递减。




Figure 6. Effect of training-set size on the test error.

3.3 MLP-assisted thin-film design

用训练完成的 MLP 对 10000 组新候选膜厚（由 `design_seed = 270027` 生成，与训练集无重叠）批量预测 41 点光谱，并按 710 nm 处的预测反射率从大到小排序。对排序后的 Top-10 候选重新调用 TMM 计算真实光谱，按 TMM 反射率确定最终 Top-5，结果见表 1。五组设计的 TMM 反射率集中在 0.6551–0.6578，彼此差距很小；MLP 对同一批结构的预测值与 TMM 真值之差不超过 0.004，但 MLP 给出的排序与 TMM 排序并不一致。图 7 为 Top-1 结构的光谱对比，该结构在 710 nm 附近处于反射率平台区，MLP 预测曲线与 TMM 真值几乎重合。




Figure 7. MLP-predicted and TMM-verified spectra of the selected design.

Rank	d1/nm	d2/nm	d3/nm	d4/nm	MLP R _{target}	TMM R _{target}
1	77.86	119.78	78.73	107.04	0.6619	0.6578
2	73.44	128.46	76.76	105.34	0.6606	0.6567

3	81.38	109.59	81.74	122.84	0.6624	0.6555
4	75.76	117.71	75.42	146.14	0.6644	0.6552
5	79.78	124.25	81.94	123.26	0.6600	0.6551

Table 1. Top five candidate thin-film designs selected by the MLP and verified using TMM.

3.4 Representative failure case

在 500 个测试样本中，误差最大的样本编号为 336，其单样本 MSE 为 6.60×10^{-4} ，约为全体测试样本平均 MSE (1.15×10^{-4}) 的 5.7 倍。该样本的膜厚为 [109.3, 109.0, 179.1, 128.5] nm，第三层厚度接近 180 nm 的采样上边界。如图 8 所示，MLP 预测曲线在 450–550 nm 区间明显抹平了真值中的干涉振荡，峰谷位置与幅度均出现偏差。




Figure 8. A representative case with relatively large MLP prediction error.

4. Discussion

从图 5 来看，MLP 以约 1% 的 RMSE 复现了膜厚到光谱的映射，说明在固定折射率、正入射条件下，四层膜光谱是关于四个厚度的光滑函数，4-128-128-64-41 的网络容量足以拟合^[8]。误差并非均匀分布：在干涉振荡剧烈、峰谷密集的波长区域，光谱对厚度的高阶敏感性更强，同样大小的厚度插值误差会放大为更大的光谱误差；反射率峰值附近导数大，允许的函数容差也更小。图 8 的失败样本正是这种情形，网络在 450–550 nm 处用更平滑的曲线代替了真实的振荡结构。

数据量实验（图 6）显示误差随样本数单调下降且边际收益递减。训练样本从 500 翻倍至 1000，RMSE 从 0.0309 降至 0.0199，下降约 35%；而从 2000 翻倍至 4000，仅从 0.0136 降至 0.0107，下降约 21%。这说明在固定网络容量与固定验证、测试集的条件下，误差的下降逐渐受限于模型自身的逼近能力，而非数据规模。若要进一步降低误差，扩充网络容量或在光谱变化剧烈的厚度区域加密采样，可能比单纯增加均匀样本更有效。

代理模型的价值主要体现在筛选速度上：10000 组候选的 MLP 预测以批量矩阵运算在数秒内完成，而 TMM 需要逐组循环计算。筛选结果还表明，排序层面的小误差不会掩盖近优结构——Top-10 候选经 TMM 复核后反射率集中在 0.655–0.658 的窄带内，最终 Top-5 均为近优设计。但 MLP 排序与 TMM 排序并不一致，个别候选的预测值偏高达约 0.004，若直接以 MLP 输出作为最终指标，会得到略失真的排名^[4]。因此在本流程中，MLP 只承担粗筛职能，最终设计决策必须由 TMM 验证。

失败案例与整体结果共同界定了本方法的能力边界。MLP 本质上是在训练分布内做插值：对靠近参数边界的样本（如 d_3 接近 180 nm）以及高振荡光谱，插值精度明显下降，网络外推到训练区间之外不可靠。本工作的其他局限包括：折射率为常数，未考虑材料色散与吸收；只考虑正入射；训练样本在厚度空间均匀采样，对高曲率区

域的覆盖不足；网络容量固定。若要推广到色散材料、斜入射或逆设计问题，需要重新构造数据集并调整模型 [4,7]。

5. Conclusions

本文针对 Air/H/L/H/L/Glass 四层介质膜构建了 TMM 数据集与 MLP 代理模型，回答了三个研究问题。(1) MLP 能够准确预测反射光谱：4000 个样本训练后，在 500 组固定测试集上的 RMSE 为 0.0107。(2) 训练样本从 500 增至 4000，测试 RMSE 由 0.0309 单调降至 0.0107，收益边际递减。(3) MLP 可承担大规模候选的快速粗筛：对 10000 组候选排序并经 TMM 复核后，得到 710 nm 处反射率 0.6578 的最优设计，但其排序与 TMM 存在小幅偏差，最终评估必须以 TMM 为准。

Data and Code Availability

The data used in this work were generated using the TMM code developed in this study. All source code, model-training scripts, thin-film screening scripts, environment dependencies, and instructions for reproducing the main results are available at:

https://github.com/PIDADQ/thin_film_pxn/

The GitHub repository should remain accessible during the current semester. The README should clearly report the student-specific `λtarget`, seed and design_seed and describe how to reproduce the main figures and results.

References

- [1] Macleod H A. Thin-Film Optical Filters. 4th ed. Boca Raton: CRC Press, 2010.
- [2] Born M, Wolf E. Principles of Optics. 7th ed. Cambridge: Cambridge University Press, 1999.
- [3] Tikhonravov A V, Trubetskov M K, DeBell G W. Application of the needle optimization technique to the design of optical coatings. *Applied Optics*, 1996, 35(28): 5493-5508.
- [4] Ma T, Ma M, Guo L J. Optical multilayer thin film structure inverse design: From optimization to deep learning. *iScience*, 2025, 28: 112222.
- [5] Peurifoy J, Shen Y, Jing L, et al. Nanophotonic inverse design with deep neural networks. *Advances in Neural Information Processing Systems*, 2018, 31.
- [6] Liu D, Tan Y, Khoram E, Yu Z. Training deep neural networks for the inverse design of nanophotonic structures. *IEEE Journal of Selected Topics in Quantum Electronics*, 2018, 24(6).
- [7] Jiang J, Chen M, Fan J A. Deep neural networks for the evaluation and design of photonic devices. *Nature Reviews Materials*, 2021, 6: 679-700.
- [8] Hornik K, Stinchcombe M, White H. Multilayer feedforward networks are universal approximators. *Neural Networks*, 1989, 2(5): 359-366.
- [9] Kingma D P, Ba J. Adam: A method for stochastic optimization. *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015.
- [10] Goodfellow I, Bengio Y, Courville A. *Deep Learning*. Cambridge: MIT Press, 2016.

课程评价

本课程系统讲解了薄膜干涉、传输矩阵法等核心理论，结合 AI4S 大作业将物理仿真与机器学习代理模型结合，让我对薄膜设计流程有了完整认知。课程理论偏抽象，部分公式推导理解难度较大。建议可增加更多工程实例演示，适当补充仿真实操课时；大作业难度合理，但可提供基础代码框架，降低入门调试门槛，帮助学生更好打通理论与实践。